

RAG 技术指南（一）：检索增强生成概述

检索增强生成（Retrieval-Augmented Generation, RAG）是一种将信息检索系统与大语言模型生成能力相结合的技术范式。它的核心思想是：在生成回答之前，先从外部知识库中检索相关文档片段（chunk），再将检索结果作为上下文注入提示词，使模型能够基于最新、最准确的知识生成答案，从而缓解大模型幻觉问题。一个完整的 RAG

链路通常包含离线索引和在线检索两条流水线。离线索引负责将 PDF 等原始文档解析为 Markdown、切分为语义块、通过 Embedding 模型向量化后写入向量数据库。在线检索则对用户查询进行向量化，在向量库中执行相似度搜索，召回最相关的候选文档，最后交给 LLM 生成带引用来源的回答。

RAG 技术指南（二）：混合检索与重排序

混合检索（Hybrid Search）是 RAG

系统提升召回质量的关键技术。它同时使用稠密检索（Dense Retrieval）和稀疏检索（Sparse Retrieval）两条通道。Dense 通道使用 Embedding 模型将文本映射到高维向量空间，通过余弦相似度捕捉语义层面的相似性，擅长处理同义词和改写表达。Sparse 通道基于 BM25 算法统计词频与逆文档频率，对专有名词、型号、编号等精确匹配场景表现优异。两条通道的召回结果通过 RRF（Reciprocal Rank

Fusion）算法融合，按倒序排名加权合并，得到统一的候选列表。融合后的结果还可以送入 Cross-Encoder 或 LLM 进行重排序（Rerank），实现精排，最终平衡查全率与查准率。

RAG 技术指南（三）：MCP 协议与 DeepSeek 多模态

MCP (Model Context Protocol) 是一种开放协议，标准化了 AI 应用与外部工具、数据源之间的连接方式。通过 MCP Server，RAG 系统的检索能力可以以标准工具的形式暴露给 Claude、GitHub Copilot 等客户端，实现一次开发、处处可用。DeepSeek 于 2026 年 4 月发布 V4-Flash 模型，具备 1M Token 上下文窗口，支持文本生成与推理。2026 年 8 月，DeepSeek 进一步发布实验性多模态模型deepseek-v4-flash-vision-exp，正式开启视觉理解能力，支持 JPEG、PNG、GIF、WebP 格式的图片输入，图片可通过 Base64 内联或 URL 方式传入。下方图片展示了本项目的 RAG Pipeline 总体架构。

RAG Pipeline 架构图

